

## 0x01 建模

- 绝大多数人服从 work-life 模型，将 work 简单粗暴地映射为挣钱。
- 为了简单起见，将目标函数设置为最高年薪（单位：w 元）。
- 考虑到各种随机因素，最高年薪在某个区间内上下浮动。因此，定义二元组  $D = \{[min, max], mle\}$ ，其中， $[min, max]$  代表最坏情况与最好情况所对应的年薪区间； $mle$  代表最可能情况所对应的年薪点。为了论述的直观性，将二元组  $D_0$  设置为具体的数字。
- 不妨假设上海脚痛大学计算机系应届硕士的最高年薪  $S$  服从正态分布  $N(60, 10^2)$ 。
- 基于  $3\sigma$  原则，将  $[min, max]$  设置为  $[\mu - 3\sigma, \mu + 3\sigma]$ ，即  $[30, 90]$ 。
- 之所以将  $mle$  设置为 50，是因为小知在同届硕士中的分位点  $\alpha$  映射至正态分布  $N(60, 10^2)$  的横坐标为 50。
- 综上，初始的最高年薪二元组  $D_0 = \{[30, 90], 50\}$ 。

**自然语言版本：**小知是上海脚痛大学计算机系的研一硕士。根据上一届学长学姐的就业数据以及个人在同届之间的相对实力，他确定了自己挣钱的小目标：最高年薪的下限是 30w，上限是 90w，最可能是 50w。

## 0x02 修正

- 考虑到每届之间的差异，有必要根据个人的绝对实力和历史的进程修正  $D_0$ 。
- 不妨假设矩阵  $A$  代表外部客观条件（学历的含金量、实验室的业内知名度、导师的人脉资源等），向量  $x$  代表个人主观条件（内卷程度、学习能力、表达能力等），向量  $b$  代表 offer（初始年薪、最高年薪、工作强度等）。设向量  $b$  的第  $k$  个元素  $b_k$  为最高年薪。
- 已知上届同分位点的学长满足  $Cx = d$ ，小知满足  $Ey = f$ 。设修正因子  $\Delta D = f(C, E, x, y, \delta)$ ，其中， $\delta$  代表由经济形势、行业兴衰等因素所造成的就业环境差异。
- 设修正三元组  $\Delta D = \{d_{min}, d_{max}, d_{mle}\}$ ，不妨令  $\Delta D = \{-10, -10, -10\}$ 。
- 综上，经过修正的最高年薪二元组  $D_0 = \{[20, 80], 40\}$ 。

**自然语言版本：**由于每届的生源质量、就业环境等因素不同，小知考虑此差异对小目标的影响。他将上届与自身水平相似的学长作为参考对象，以二人的外部客观条件（学历的含金量、实验室的业内知名度、导师的人脉资源等）、个人主观条件（内卷程度、学习能力、表达能力等）和就业环境差异（经济形势、行业兴衰等）作为修正小目标的依据。经此修正，他的小目标变成了：最高年薪的下限是 20w，上限是 80w，最可能是 40w。

## 0x03 决策

- 设个人综合实力所对应的最高年薪为  $\beta_k$ ，工作所对应的最高年薪为  $\gamma_k$ ，工作的获取概率  $p = g(\beta_k, \gamma_k)$ ， $p \in [0, 1]$ 。

- 记获取概率向量  $P = (p_1, p_2, \dots, p_n)^T$ ， $p_k$  代表第  $k$  种工作的获取概率；记最高年薪向量  $\gamma = (\gamma_1, \gamma_2, \dots, \gamma_n)^T$ ， $\gamma_k$  代表第  $k$  种工作的最高年薪。
- 为了数学期望最大化，小知所选定的工作满足  $p_t \cdot \gamma_t = \max(p_i \cdot \gamma_i), i \in \{1, 2, \dots, n\}$ 。为了简单起见，设 offer 所构成的集合为  $\{A, B\}$ ，其中，获取概率  $(\alpha_A, \alpha_B) = (0.8, 0.75)$ ；最高年薪  $(\gamma_A, \gamma_B) = (45, 50)$ 。
- 工作  $A$  最高年薪的数学期望是  $0.8 \times 45 = 36$ ；工作  $B$  最高年薪的数学期望是  $0.75 \times 50 = 37.5$ 。因此，小知将工作  $B$  所对应的技能树  $T_B$  作为学习目标。
- 综上，小知以最高年薪的数学期望为  $37.5$  的工作  $B$  为目标，学习其技能树  $T_B$ 。

**自然语言版本：**小知在软件开发工程师和程序分析研究员两个岗位之中纠结：前者的成功率更高，但待遇更低；后者反之。根据薪资分布、主观条件（对技能树的偏好、学习基础等）、客观条件（实验室资源、学习难度等），他量化了二者的成功率和最高年薪，选择了数学期望更大的程序分析研究员。

## 0x04 计划

- 在技能树  $T_B$  的学习过程中，小知的实力  $I_B$  逐渐提高。显然， $I_B$  是关于时间  $t$  的函数。
- 定义打工人集合  $\Phi = \{\phi_1, \phi_2, \dots, \phi_n\}$ ，且  $\phi_M$  为该集合的“广义众数”。
- 设  $I'_B(t) = h(\phi_M, t)$ ，其中， $h(\phi_M, t)$  是面向工作  $B$  所需技能树的一般化学习曲线。
- 为了便于分配学习任务并及时地获得正反馈，将总区间  $[t_0, t_0 + \Delta t)$  依“年、月、周、日、时”划分为若干子区间。不妨设  $t_0 = 0$ ， $\Delta t = 2.5$ （单位：年）。

**自然语言版本：**小知按照程序分析研究员的招聘要求确定了第1年、第2年和第3年的学习目标；年初时，他将该年的学习目标划分为每月的学习小目标；月初时，他将该月的学习小目标划分为1h左右的学习任务；周日时，他选取若干学习任务作为每周学习计划；最后，他将每周学习计划的学习任务分配至各个工作日。

## 0x05 迭代

- 将学习周期分为三个阶段：计划、执行和总结，即  $(P, E, S)$ 。
- 为了简单起见，暂时固定执行  $E$  和总结  $S$ 。
- 执行  $E$  和总结  $S$  不断地产出后验知识，该后验知识可以用于优化计划  $P$ 。因此，不妨以天为单位，将  $p^{(i)}$  定义为第  $i$  天的计划能力。
- $\exists k > 0, \forall N > k$ ，使得  $|p^{(N)} - p| < \epsilon$ ，即： $p^{(n)}$  收敛于  $p$ 。
- 执行能力  $e$  与总结能力  $s$  亦同。

**自然语言版本：**每天早晨，小知确定当天的学习任务；根据当天的学习反馈，他总结学习任务的合理性以提升计划能力、总结学习任务的执行情况以提升执行能力。随着学习的深入，小知的总结能力也不断提升。

## 0x06 总结

- 在旷日持久的学习之后，小知的实力达到了  $X_B$ ，而且向  $X_B \pm 3\sigma_B$  的所有岗位投递了简历。
- 经过层层筛选，小知收到了  $m$  个 offer。
- 对于 offer 所构成的集合  $O = \{o_1, o_2, \dots, o_m\}$ ，小知选择了  $o_{max} = \max \{o_i\}, i \in \{1, 2, \dots, m\}$ 。设  $O = \{23, 26, 33, 42\}$ ，则  $o_{max} = 42$ 。
- 小知分析了以最高年薪为导向的初态  $state(t_0)$ 、学习过程  $p(T_B)$ 、终态  $state(t_0 + \Delta t)$ ，将本轮学习所产出的后验知识注入认知体系，比之前更优秀了。

**自然语言版本：**经过两年半的学习，小知根据自身实力海投简历。经过层层筛选，他获得了最高年薪分别为23w、26w、33w和42w的一众 offer，并选择了42w的 offer。他总结本轮学习以更新认知体系，比之前更优秀了。